В этом домашнем задании Вам предстоит поближе познакомиться с [распределенной файловой системой HDFS] (http://hadoop.apache.org/docs/r1.2.1/hdfs\_design.html). Ваша цель - написать скрипты, которые будут делать HTTP запросы к различным демонам HDFS или вызовать стандартные утилиты командной строки (shell) с целью получения запрашиваемой информации.

Можно использовать любой скриптовый язык программирования. Самый простой вариант - использовать bash, а также утилиты curl, grep, wc и т.п.

Решение каждой задачи помещайте в отдельных директориях (в домашней директории на клиентском сервере) с именами  $hw1\task01$ ,  $hw1\task02$  и т.д. Там, где не указано иное, решение надо оформить в виде исполняемого скрипта `run.sh`.

```
> Даже если разрабатываете на Python, `run.sh` может содержать только
вызов нужного скрипта, например:
     #!/usr/bin/env bash
     python my python script.py $*
> Тут $* обеспечит передачу параметров, с которыми был вызван `run.sh` в
`my python script.py`.
### Задачи
#### АА (0.1 балла)
Запишите в свою домашнюю директорию в HDFS файл `README`, содержащий:
* в первой строке - ваш e-mail
* во второй строке - имя и фамилию
Не путайте строки и имя с фамилией. Задача проверяется по наличию файла.
#### ВВ (0.1 балла)
Создайте текстовый файл размером не больше 5 МВ. Желательно именно с
текстом, а не с html, xml и прочей разметкой. Можно откуда-то
скопировать, можно скачать.
> Хорошо подходит для этого lib.ru, вот так можно получить всего "Евгения
Онегина":
     $ wget "http://lib.ru/LITRA/PUSHKIN/p4.txt"
> только возможно придется поправить кодировку одним из способов:
      $ cat p4.txt | iconv -f windows-1251 -t utf8 p4 utf.txt
     $ cat p4.txt | iconv -f koi8-r -t utf8 p4_utf.txt
> Главное, чтобы в итоге команда:
     $ more <file>
> выдавала читаемый текст.
```

Создайте в домашней директории в HDFS директорию text/full и запишите туда полученный файл. Выделите 50 первых строк файла в отдельный файл (удобно с помощью команды head), запишите в директорию text/sample. Задача проверяется по наличию директорий и файлов. \*Не качайте все одно и то же!\*

```
#### 01 (0.1 балла)
```

На вход скрипту подается имя файла, на выходе нужно получить имя сервера или IP-адрес, с которого будет читаться первый блок данных (реплик может быть несколько, засчитываться будет любой из них). Пример:

\$ ./run.sh /data/access\_logs/big\_log/access.log.2015-12-10
mipt-node01.atp-fivt.org

### #### 02 (0.1 балла)

На вход скрипту подается имя файла, на выходе нужно получить первые 10 байт этого файла (hadoop fs и hdfs dfs использовать нельзя)

\$ ./run.sh /data/access\_logs/big\_log/access.log.2015-12-10
41.190.60.

## #### 03 (0.1 балла)

На вход скрипту подается полный путь до файла в HDFS, на выходе нужно получить размер файла в блоках (см. hdfs fsck -h).

\$ ./run.sh /data/access\_logs/big\_log/access.log.2015-12-10
8

## #### 04 (0.1 балла)

На вход скрипту подается идентификатор блока, на выходе нужно получить имя сервера (если их несколько, то выбрать любой), где хранится данный блок и физический путь в локальной файловой системе до этого блока данных. (О том, как зайти на ноды кластера, написано в материалам Семинара по HDFS)

\$ ./run.sh blk 1075127191

bds03.vdi.mipt.ru:/dfs/dn/current/BP-76251478-10.55.163.141-1427134131440/current/finalized/subdir21/subdir35/blk 1075127191

### #### 05 (0.2 балла)

Большие файлы на кластере делятся на блоки определенного размера. Нужно выяснить какой дополнительный объем используется в HDFS для хранения данных при использовании одной реплики (т.е. без дублирования данных). Для проведения экспериментов и создания файлов разного размера предлагается использовать утилиту dd (см. [пример использования] (http://unix.stackexchange.com/questions/101332/generate-file-of-a-certain-size)) + решение задачи 4. На вход программы подается размер файла в байтах, на выходе программы должно быть одно число, равное числу байт для физического хранения этого файла (без учета хранения файлов с расширением .meta). Из полученного результата вычесть объём исходного файла (в байтах).

\$ ./run.sh <int>
123

Исследовательская задача (0.5 балла),

# #### 06 (0.5 балла)

На выходе - отчет, принимается только в случае сдачи в срок всех предыдущих задач.

Допустим у нас имеется 32GB RAM на сервере, где у нас установлен сервис Namenode. 6GB RAM зарезервировано на различные сервисы для мониторинга состояния кластера и поддержки работоспособности системы. Объем метаинформации на 1 блок - 200 байт.

- 1. В предположении 3-кратной репликации оценить максимальный объем данных, которые можно хранить на кластере (стандартный размер блока: 64 или 128 MB).
- 2. Сколько данных можно хранить на кластере, если Secondary Namenode работает на той же машине, что и Namenode?
- 3. Как изменится этот показатель в предположении того, что средний размер файла в блоках 1.5?
- 4. Допустим к нам пришел заказчик и сказал, что собирается хранить и обрабатывать на наших серверах 120РВ данных. Какой минимальный объем оперативной памяти должен быть установлен при вышеуказанных параметрах реплицирования, размера блока и средней длины файла в блоках?